# ConcretoAI

**Estimativa da resistência à compressão do concreto com Machine Learning**

Trabalho final da disciplina Machine Learning Pós-Graduação em IA Generativa e Aplicações com LLMs — PUC Minas Professor: Maurício Rodrigues da Silva

Integrantes: Carlos, Eduardo, Mateus, Paulo e Yara Vitoria Sampaio Braga

Novembro de 2026

## 2. Introdução

### 2.1 Contexto

A resistência à compressão é uma das propriedades mais importantes do concreto, material amplamente usado na construção civil. Ela é medida em laboratório, por meio de ensaios em corpos de prova que precisam de dias de cura antes de serem rompidos. O valor depende da composição da mistura (cimento, escória de alto-forno, cinza volante, água, superplastificante e agregados graúdo e miúdo) e da idade do concreto no momento do ensaio.

Como essa relação é complexa e envolve interações entre os componentes, ela é um problema clássico para modelos de aprendizado de máquina supervisionado. A base pública *Concrete Compressive Strength*, do UCI Machine Learning Repository, reúne ensaios de laboratório com a composição de cada mistura, a idade e a resistência medida, e é usada neste trabalho.

### 2.2 Justificativa

Estimar a resistência a partir da receita permite explorar misturas antes de produzi-las e ensaiá-las, o que economiza tempo e material nas fases iniciais de estudo. Além do interesse prático, o problema é adequado à disciplina: o alvo é contínuo, os dados são tabulares e numéricos, e há uma questão metodológica relevante, que é avaliar o modelo sem inflar o resultado por causa de registros repetidos entre treino e teste.

O modelo desenvolvido não substitui o ensaio de laboratório. Ele oferece uma estimativa exploratória, e suas limitações são discutidas ao longo do relatório.

### 2.3 Objetivo

**Objetivo geral:** estimar a resistência à compressão do concreto (em MPa) a partir da composição da mistura (em kg/m³) e da idade (em dias), usando regressão supervisionada, e disponibilizar o modelo em uma interface web.

**Objetivos específicos:**

- inspecionar e tratar a base de dados, documentando cada decisão;
- separar treino e teste por grupos, evitando que entradas idênticas apareçam nos dois conjuntos;
- comparar os modelos Ridge e Random Forest por validação cruzada, tendo como referência a previsão pela média;
- avaliar o modelo escolhido uma única vez no conjunto de teste, com RMSE, MAE e $R^2$;
- exportar o pipeline treinado para uso pela interface.

### 2.4 Organização do relatório

A seção 3 apresenta o dataset. A seção 4 descreve a metodologia. A seção 5 traz os resultados. A seção 6 descreve a interface gráfica e a seção 7 apresenta a conclusão e a contribuição de cada integrante.

## 3. Dataset

### 3.1 Fonte

Os dados vêm da base pública *Concrete Compressive Strength*, do UCI Machine Learning Repository (https://archive.ics.uci.edu/dataset/165/concrete+compressive+strength; DOI https://doi.org/10.24432/C5PK67). O criador e doador é I-Cheng Yeh, da Chung-Hua University, em Taiwan, e a base foi doada em 3 de agosto de 2007. O uso segue a licença Creative Commons Attribution 4.0 (CC BY 4.0), com atribuição ao autor.

Conforme pede o readme original da fonte, a referência é:

I-Cheng Yeh. “Modeling of strength of high performance concrete using artificial neural networks.” *Cement and Concrete Research*, Vol. 28, No. 12, pp. 1797–1808, 1998. DOI: 10.1016/S0008-8846(98)00165-3.

O arquivo original ( `Concrete_Data.xls` , planilha `Sheet1` ) foi lido sem nenhuma alteração. As planilhas `Sheet2` e `Sheet3` foram conferidas e estão vazias. Os nomes das colunas originais foram renomeados em memória, por um mapeamento explícito, apenas para

facilitar o uso.

## 3.2 Estrutura da base

A base lida contém **1030 registros** e **9 colunas**: 8 variáveis de entrada e 1 variável de saída (alvo). Todas as colunas são numéricas (oito do tipo `float64` e a idade como `int64`), não há valores nulos e, por isso, não foi necessário nenhum *encoding* de variáveis categóricas.

| Coluna (nome no trabalho) | Papel | Unidade |
|---|---|---|
| Cimento ( `cimento` ) | entrada | kg por m³ de mistura |
| Escória de alto-forno ( `escoria` ) | entrada | kg por m³ de mistura |
| Cinza volante ( `cinza_volante` ) | entrada | kg por m³ de mistura |
| Água ( `agua` ) | entrada | kg por m³ de mistura |
| Superplastificante ( `superplastificante` ) | entrada | kg por m³ de mistura |
| Agregado graúdo ( `agregado_graudo` ) | entrada | kg por m³ de mistura |
| Agregado miúdo ( `agregado_miudo` ) | entrada | kg por m³ de mistura |
| Idade ( `idade_dias` ) | entrada | dias (1 a 365) |
| Resistência à compressão ( `resistencia_mpa` ) | **alvo** | MPa |

Na base completa, a resistência varia de 2,33 a 82,60 MPa, com média de 35,82 MPa e mediana de 34,44 MPa. Os componentes têm escalas muito diferentes: o agregado graúdo chega a 1145 kg/m³, enquanto o superplastificante chega a 32,2 kg/m³. Essa diferença de escala justifica a padronização dentro do pipeline, principalmente para o Ridge.

In [4]:
```
print("shape (registros, colunas):", df.shape)
df.head()
```

```
shape (registros, colunas): (1030, 9)
```

Out[4]:

| | cimento | escoria | cinza_volante | agua | superplastificante | agregado_graudo | agregado_miudo | idade_dias | resistencia_mpa |
|---|---|---|---|---|---|---|---|---|---|
| **0** | 540.0 | 0.0 | 0.0 | 162.0 | 2.5 | 1040.0 | 676.0 | 28 | 79.986111 |
| **1** | 540.0 | 0.0 | 0.0 | 162.0 | 2.5 | 1055.0 | 676.0 | 28 | 61.887366 |
| **2** | 332.5 | 142.5 | 0.0 | 228.0 | 0.0 | 932.0 | 594.0 | 270 | 40.269535 |
| **3** | 332.5 | 142.5 | 0.0 | 228.0 | 0.0 | 932.0 | 594.0 | 365 | 41.052780 |
| **4** | 198.6 | 132.4 | 0.0 | 192.0 | 0.0 | 978.4 | 825.5 | 360 | 44.296075 |

In [5]:
```
df.info()
```

```
<class 'pandas.DataFrame'>
RangeIndex: 1030 entries, 0 to 1029
Data columns (total 9 columns):
 #   Column              Non-Null Count  Dtype  
---  ------              --------------  -----  
 0   cimento             1030 non-null   float64
 1   escoria             1030 non-null   float64
 2   cinza_volante       1030 non-null   float64
 3   agua                1030 non-null   float64
 4   superplastificante  1030 non-null   float64
 5   agregado_graudo     1030 non-null   float64
 6   agregado_miudo      1030 non-null   float64
 7   idade_dias          1030 non-null   int64  
 8   resistencia_mpa     1030 non-null   float64
dtypes: float64(8), int64(1)
memory usage: 72.6 KB
```

*Print dos dados — saída de df.head() e df.info() no notebook.*

## 3.3 Qualidade dos dados

- **Valores nulos:** nenhum, em todas as colunas.
- **Zeros:** aparecem em escória (466 registros, 45,2 %), cinza volante (566, 55,0 %) e superplastificante (379, 36,8 %). Em concreto, zero nesses componentes significa que eles não foram usados na mistura. É um valor legítimo e não foi tratado como dado ausente.
- **Duplicatas exatas:** 36 linhas pertencem a 11 grupos de linhas totalmente idênticas, o que dá 25 linhas redundantes (cópias além da primeira ocorrência).
- **Conflitos:** 19 combinações de entradas se repetem e, em 9 delas, a mesma entrada tem resistências diferentes. As diferenças costumam ser pequenas, de 1 a 7 MPa, com uma exceção: uma mistura com cimento de 362,6 kg/m³ e idade de 7 dias, que tem quatro linhas entre 22,9 e 55,9 MPa. Isso é esperado em dados de laboratório, pela variabilidade do ensaio, e indica um limite de ruído que nenhum modelo elimina.

## 3.4 Decisões de tratamento

A decisão do projeto foi remover apenas as **duplicatas exatas** (linhas iguais nas nove colunas), mantendo a primeira ocorrência. O objetivo é evitar que registros indistinguíveis pesem mais no treino e inflem a avaliação. Com isso, a base de trabalho passou de **1030**

**para 1005 registros**. O grupo não afirma que essas linhas sejam comprovadamente o mesmo ensaio; o que se sabe é que, nos dados, elas não se distinguem.

Foram preservados: as 9 combinações de entradas iguais com resistências diferentes (sem calcular média nem escolher um dos valores, porque a causa da diferença não foi comprovada), todos os zeros legítimos (1384 no total, somando escória, cinza volante e superplastificante) e os valores extremos. Nenhum *outlier* foi removido automaticamente, pois a variação faz parte do domínio.

# 4. Metodologia

## 4.1 Visão geral do fluxo

O trabalho foi feito em um notebook Jupyter (Python 3.12, scikit-learn 1.9.1, pandas, numpy, matplotlib e seaborn) com semente fixa (`random_state=42`) para reprodutibilidade. O fluxo foi: inspeção e tratamento dos dados, separação treino/teste por grupos, análise exploratória só no treino, comparação de modelos por validação cruzada, escolha do modelo, avaliação final única no teste e exportação do pipeline.

## 4.2 Separação treino/teste por grupos

Existem entradas idênticas na base. Se linhas assim caíssem uma no treino e outra no teste, o modelo seria avaliado em algo que já viu, e o desempenho ficaria otimista. Por isso a separação foi feita **por grupos**: cada grupo é uma combinação exata das oito entradas (o alvo não é usado), e linhas do mesmo grupo ficam sempre no mesmo conjunto.

Foi usado `GroupShuffleSplit` com 20 % para teste e `random_state=42`, uma única vez, sem trocar a separação depois de ver resultados. O identificador do grupo serve só para separar e validar; ele não entra como variável do modelo.

| Conjunto | Linhas | Grupos |
|---|---|---|
| Treino | 803 (79,9 %) | 796 |
| Teste | 202 (20,1 %) | 200 |
| Total | 1005 | 996 |

Uma verificação explícita confirmou que nenhum grupo aparece nos dois conjuntos. O registro da separação está em `data/processed/split_treino_teste.csv`. O conjunto de teste ficou reservado para a avaliação final e não foi inspecionado durante a análise exploratória nem a escolha do modelo.

## 4.3 Pré-processamento

O pré-processamento fica dentro de um `Pipeline` do scikit-learn, em três etapas: imputador (`SimpleImputer`, estratégia da mediana) → padronização (`StandardScaler`) → modelo. Como os transformadores são ajustados apenas nos dados de treino de cada fold, nenhuma estatística do conjunto de validação ou de teste vaza para o ajuste. Embora a base não tenha valores nulos, o imputador faz parte do pipeline para que ele continue funcionando se houver entradas faltantes.

A padronização ajuda o Ridge, que é sensível à escala das variáveis. Árvores não a exigem, mas ela foi mantida no Random Forest para ter um fluxo comum aos modelos e exportar o *scaler* explicitamente.

## 4.4 Modelos testados

- **Ridge:** regressão linear regularizada, usada como comparação simples e interpretável (`alpha=1.0`).
- **Random Forest** (`RandomForestRegressor`): combinação de árvores de decisão, capaz de capturar relações não lineares e interações entre componentes (200 árvores, `min_samples_leaf=2`, `random_state=42`).
- **Referência pela média** (`DummyRegressor`): prevê sempre a média do alvo no treino. Serve para saber se os modelos acrescentam valor.

Os hiperparâmetros foram fixados antes de abrir o teste e **não houve busca de hiperparâmetros**.

## 4.5 Validação cruzada

A comparação dos modelos usou `GroupKFold` com cinco folds, aplicado só ao conjunto de treino e com os mesmos folds para os três modelos. A divisão é determinística e, em todos os folds, os grupos de ajuste e de validação são disjuntos. Cada fold usa cerca de 642 a 643 linhas para ajuste e 160 a 161 para validação.

O critério de escolha foi definido antes de olhar o teste: entre Ridge e Random Forest, vence o menor RMSE médio de validação cruzada. A referência pela média serve só como parâmetro.

### 4.6 Métricas

- **RMSE** (raiz do erro quadrático médio, em MPa): penaliza mais os erros grandes. É a métrica usada para escolher o modelo.
- **MAE** (erro absoluto médio, em MPa): o erro típico, mais fácil de interpretar.
- **$R^2$:** fração da variação do alvo explicada pelo modelo; vale 0 quando o modelo não faz melhor do que prever a média.
- **Gráfico real × previsto:** mostra visualmente onde o modelo acerta e onde se afasta.

## 5. Resultados

### 5.1 Análise exploratória (somente no treino)

A análise exploratória foi feita só com as 803 linhas de treino.

**Cimento.** O teor vai de 102 a 540 kg/m³, com média (279,4) acima da mediana (266,0) e assimetria positiva de 0,53. O histograma tem vários picos, o que sugere que a base reúne famílias de misturas definidas em experimentos, e não uma população contínua e regular.

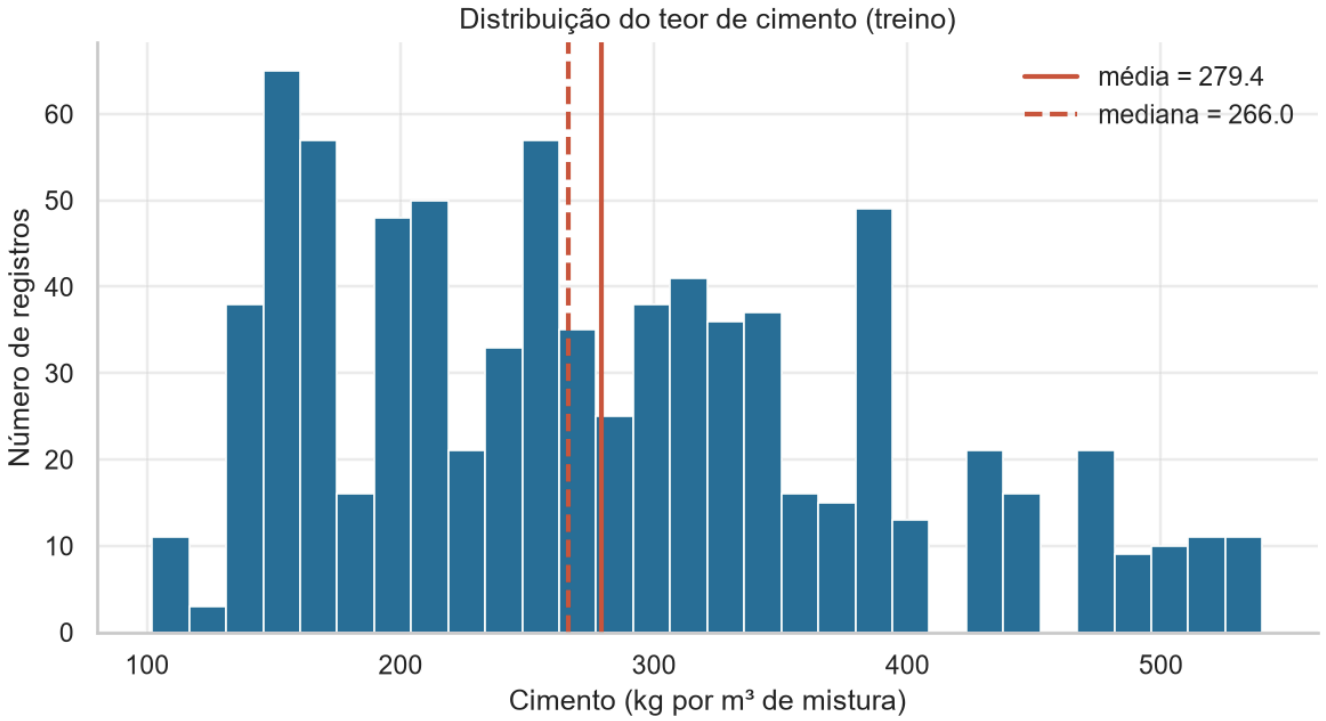


*Figura 1 — Distribuição do teor de cimento no treino.*

**Resistência (alvo).** Varia de 2,33 a 82,60 MPa, com média de 35,3 e mediana de 33,8 MPa. A distribuição é aproximadamente unimodal, com leve assimetria à direita (0,42) e poucos valores acima de 70 MPa. Como o alvo é contínuo e sem desbalanceamento de classes, a regressão é adequada.

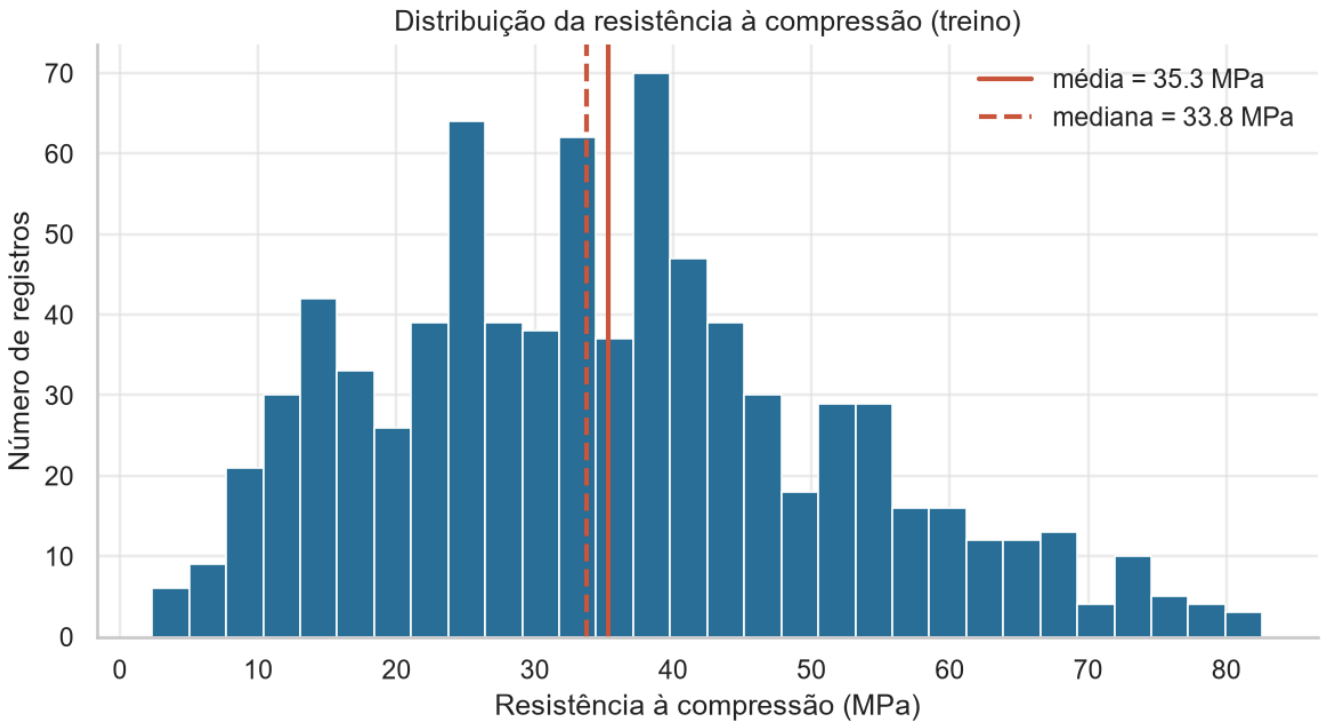



*Figura 2 — Distribuição da resistência à compressão no treino.*

**Correlações.** A correlação de Pearson com a resistência é, em ordem: cimento +0,51, superplastificante +0,37, idade +0,33, água −0,30, agregado miúdo −0,18, agregado graúdo −0,13, cinza volante −0,08 e escória +0,08. O cimento é a entrada mais associada ao alvo, mas nenhuma correlação passa de 0,51, o que mostra que nenhuma variável isolada explica a resistência. Entre as entradas, o par mais correlacionado é água × superplastificante (−0,65): misturas com mais aditivo tendem a ter menos água. A correlação mede associação linear e não prova causalidade; por exemplo, a correlação positiva do superplastificante pode refletir a redução de água que ele acompanha, e não um efeito direto.

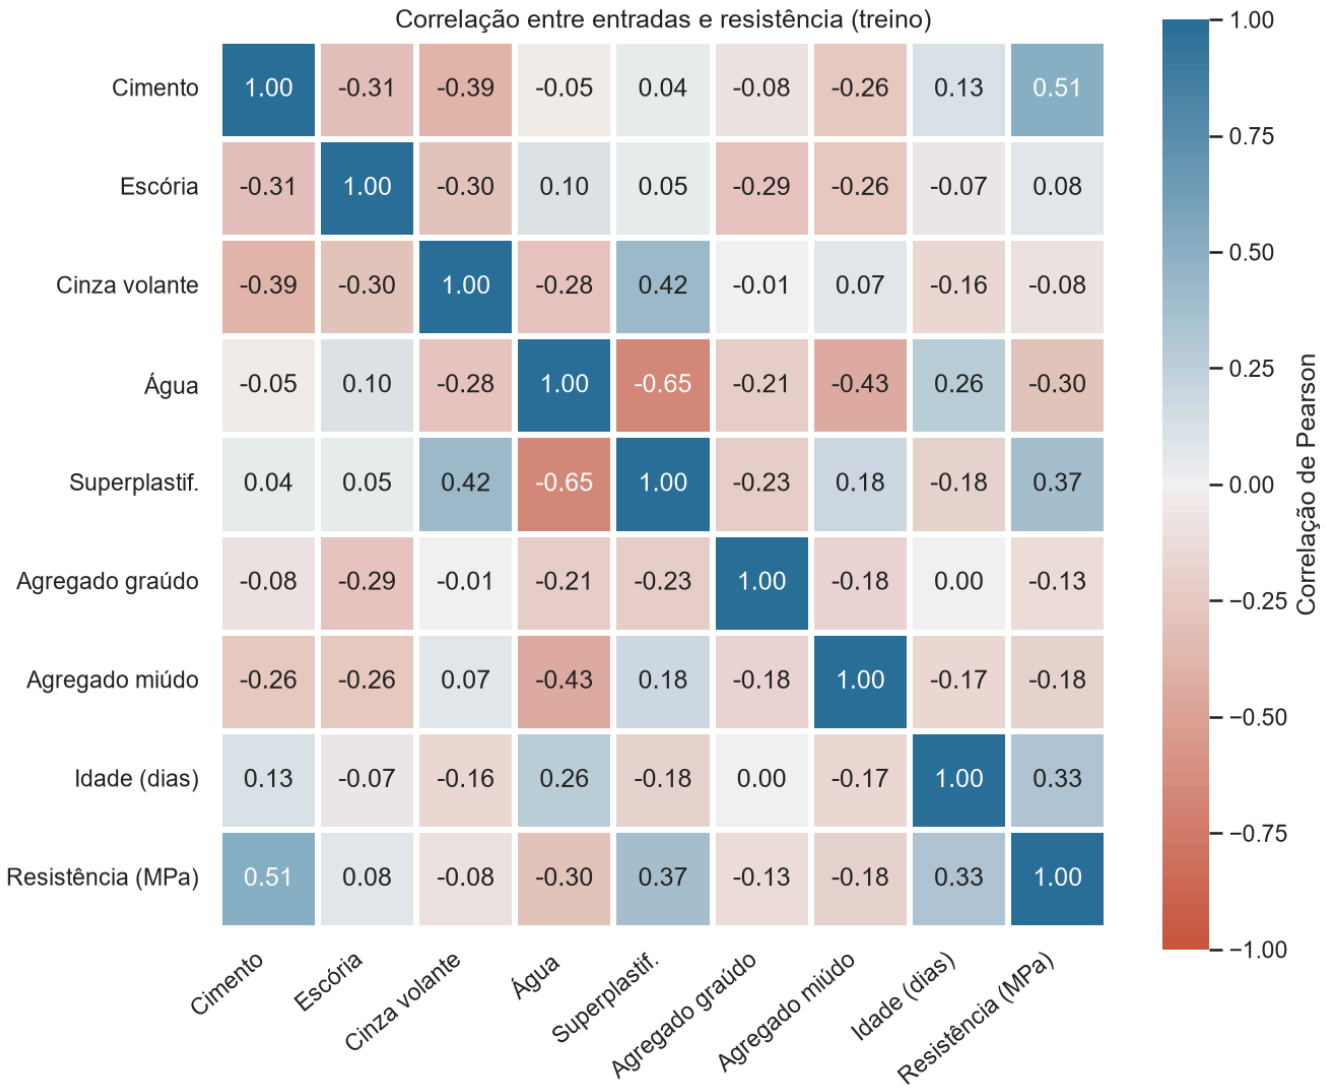



*Figura 3 — Matriz de correlação entre entradas e resistência.*

**Idade.** O treino tem apenas 14 idades distintas, e a de 28 dias concentra 330 dos 803 registros (41 %). A resistência mediana cresce das idades curtas para as longas: 14,9 MPa aos 3 dias, 21,3 aos 7, 33,5 aos 28 e 49,9 aos 56 dias. Depois disso o padrão deixa de ser monotônico (39,7 aos 90 dias, 47,0 aos 100 e 41,4 aos 180), o que indica que as misturas medidas em idades longas não são as mesmas das idades curtas. Em cada idade a dispersão é grande (aos 28 dias, de 8,5 a 81,8 MPa), logo a idade sozinha não determina a resistência. A relação é não linear, com crescimento rápido no início e estabilização depois, e por isso a correlação linear de 0,33 subestima a importância da idade.

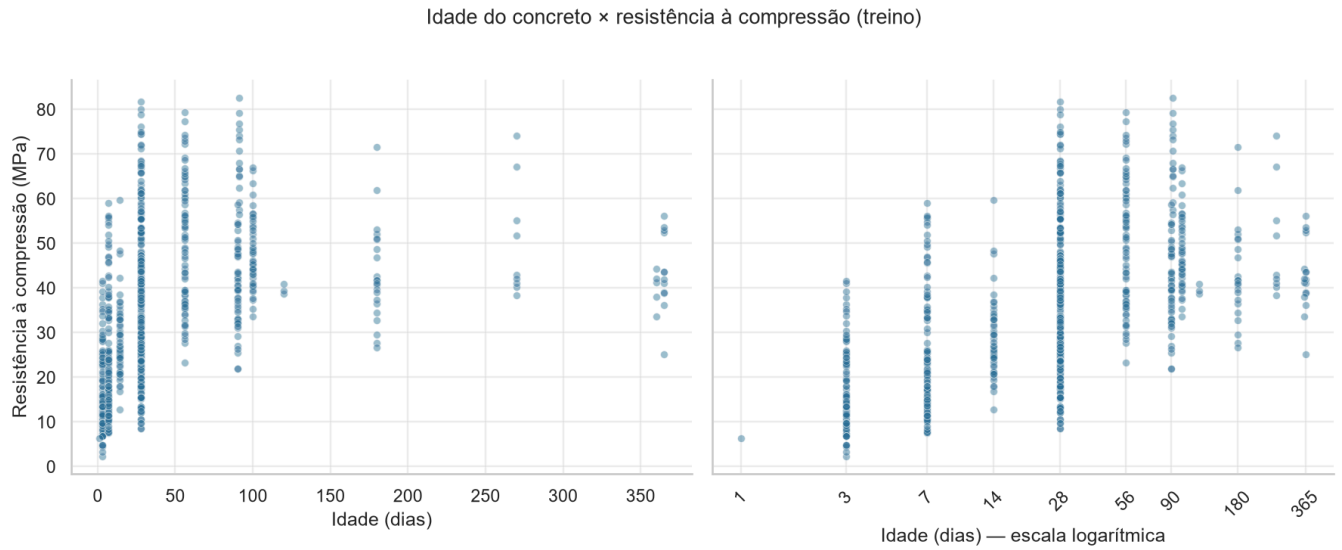



*Figura 4 — Idade do concreto × resistência, em escala linear e logarítmica.*

## 5.2 Comparação dos modelos por validação cruzada

A tabela traz a média e o desvio-padrão entre os cinco folds, só no treino.

| Modelo | RMSE médio (MPa) | MAE médio (MPa) | $R^2$ médio |
|---|---|---|---|
| Random Forest | 5,58 (±0,52) | 3,96 (±0,21) | 0,885 (±0,025) |
| Ridge | 10,33 (±0,60) | 8,20 (±0,26) | 0,606 (±0,061) |
| Referência (média) | 16,52 (±0,39) | 13,34 (±0,56) | −0,001 (±0,001) |

Prever sempre a média do treino dá RMSE de 16,52 MPa e $R^2$ próximo de zero. Os dois modelos ficam bem abaixo disso. A diferença média de RMSE entre Ridge e Random Forest é de cerca de 4,7 MPa, muito maior que o desvio entre folds (0,6 e 0,5 MPa). Com apenas cinco folds não há teste estatístico, mas a distância é grande para ser atribuída à variação das divisões. O Random Forest foi melhor em todos os folds (RMSE de 5,18 a 6,44 MPa, contra 9,39 a 10,96 MPa do Ridge).

O **Random Forest foi escolhido** pelo menor RMSE médio de validação cruzada, critério definido antes de abrir o teste. O resultado é coerente com a análise exploratória: a idade tem relação não linear com a resistência e os componentes interagem, o que um modelo linear captura mal.

## 5.3 Avaliação final no conjunto de teste

O Random Forest foi ajustado em todo o treino (803 linhas) e avaliado uma única vez nas 202 linhas de teste.

| Modelo | RMSE (MPa) | MAE (MPa) | $R^2$ |
|---|---|---|---|
| Random Forest | 4,67 | 3,44 | 0,906 |

O RMSE de 4,67 MPa e o MAE de 3,44 MPa indicam que a previsão erra, em média, algo entre 3 e 5 MPa. O $R^2$ de 0,906 significa que o modelo explica cerca de 91 % da variação da resistência no conjunto de teste. O erro no teste ficou abaixo do da validação cruzada (5,58 MPa). Com um único conjunto de 202 linhas e um treino maior, isso é plausível e não deve ser lido como melhora real.

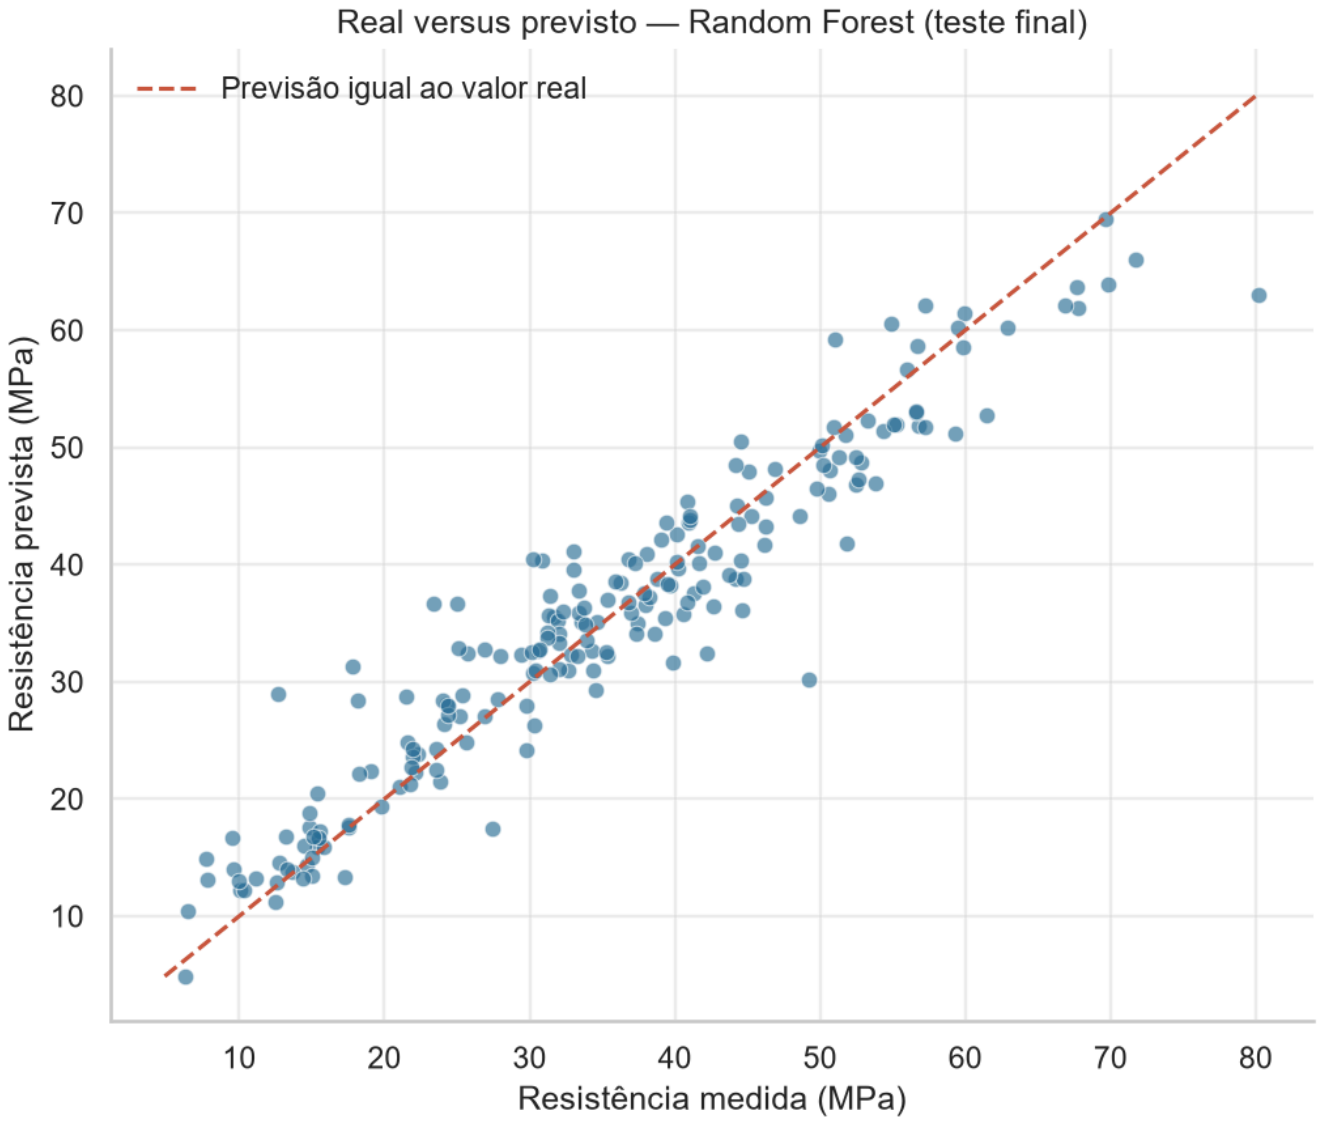


*Figura 5 — Resistência medida × prevista no teste final.*

Os pontos se concentram em torno da diagonal e o viés médio é pequeno (cerca de +0,2 MPa). Nas pontas o modelo se afasta mais: abaixo de 20 MPa tende a superestimar (+2,6 MPa em média) e acima de 60 MPa tende a subestimar (−6,1 MPa, com RMSE de 7,6 MPa, em apenas 9 pontos). Esse comportamento é esperado em uma floresta, que puxa as previsões para a média onde há poucos exemplos.

## 5.4 Limitações dos resultados

- Os números descrevem o desempenho neste conjunto de teste e neste protocolo. Não mostram que o modelo serve para decisão estrutural, e não há critério externo de tolerância para classificar o erro como aceitável ou não.
- O agrupamento pelas oito entradas impede que entradas idênticas apareçam nos dois conjuntos, mas não impede que a mesma composição em idades diferentes apareça em ambos. Assim, a avaliação mede o desempenho em combinações de entradas não vistas, e não garante generalização para receitas completamente inéditas.
- Os hiperparâmetros foram fixados sem busca, a validação usou apenas cinco folds e os dados vêm de um único estudo, com poucas idades e muitas misturas repetidas em idades diferentes.
- Há um limite de ruído nos próprios dados: nove combinações de entradas iguais têm resistências diferentes, e nenhum modelo elimina essa variabilidade.